Pratique de la fiabilité – Partie 3

Fiabilité bayésienne

emmanuel.remy@edf.fr

ISUP – Année scolaire 2025-2026

Démarche générale vis-à-vis des connaissances

Evénement : défaillance de capteurs

Un REX* de défaillances important

FIABILITE FREQUENTISTE (CLASSIQUE)

* Retour d'EXpérience (événementiel)

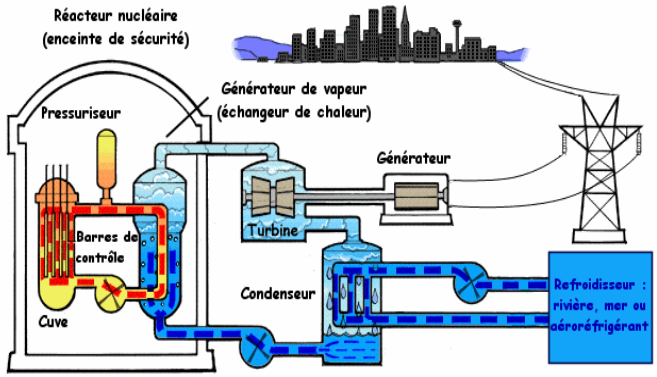

Un REX faible, mais des avis d'experts

FIABILITE BAYESIENNE

Evénement : panne d'une pompe

Evénement : rupture d'un barrage

Pas de REX de défaillances, mais un modèle physique / code de simulation numérique

FIABILITE STRUCTURELLE – INCERTITUDES EN SIMULATION NUMERIQUE

N.B : dans la pratique, ces approches peuvent être combinées, ou l'une produit des données d'entrée pour une autre…

Plan de la partie 3

- Plan de la partie 3 :
  - Intérêt et motivation de l'approche bayésienne en fiabilité industrielle et à EDF
  - Formule de Bayes : interprétations possibles de la probabilité, indépendance et probabilité conditionnelle, formule de Bayes et interprétation
  - Approche bayésienne : principes de l'approche et de l'inférence bayésiennes, comparaison avec l'approche fréquentiste
  - Approche bayésienne en fiabilité industrielle : rappel sur les données de REX et l'expression de la fonction de vraisemblance, cas du modèle exponentiel (cadre de conjugaison, loi *a priori* non informative de Jeffreys, quelques éléments sur la construction d'*a priori*), cas du modèle de Weibull et méthodes Monte-Carlo pour l'estimation de la loi *a posteriori* (échantillonnage pondéré, MCMC dont Metropolis-Hastings), méthode ABC
  - Extensions possibles : compatibilité entre données de REX et loi *a priori*, critère DAC, utilisation de la loi *a posteriori*, réseaux bayésiens
  - Cas d'étude EDF pour illustration : durées de vie du condenseur et du réducteur de pompes
  - Outils logiciels : WinBUGS, OpenBUGS, JAGS, R, Python
  - Références bibliographiques
  - Quelques éléments de conclusion

Intérêt et motivation de l'approche bayésienne en fiabilité industrielle et à EDF

Intérêt de l'approche bayésienne en fiabilité industrielle

- Rareté des données de REX :
  - Matériels fiables et maintenus, donc peu de défaillances
- Statistique fréquentiste se prêtant mal aux données rares :
  - Hypothèses de statistique classique souvent vraies asymptotiquement (utilisation du théorème central limite)…
  - … Donc pas systématiquement justes dans le contexte de la fiabilité industrielle
- La mise en œuvre de l'approche bayésienne impose de préciser explicitement toutes les distributions en support des paramètres modélisés
- Le bayésien n'est pas plus "juste" que le fréquentiste, mais il permet d'expliciter des hypothèses qui sont prises implicitement

Motivation de l'approche bayésienne à EDF

- Contexte industriel EDF : exigences de sûreté, performance, rareté des défaillances
- Peu de défaillances, mais exigence de les "exploiter" au mieux
- Si on reste au niveau des données de REX, la possibilité de modéliser un apport de connaissance est intéressante
- Le bayésien permet (nécessite) un apport de connaissance "experte" pour quantifier la fiabilité à partir des données de REX collectées, d'où :
  - Une meilleure estimation de la fiabilité
  - Une incertitude réduite
  - Une meilleure maîtrise des hypothèses sous-jacentes au calcul

- Une référence intéressante : *Application of bayesian methods in reliability data analyses*, W.Q. Meeker & M. Li, Journal of Quality Technology, vol. 46(1), pp. 1-23, 2014

Formule de Bayes

Deux interprétations différentes de la probabilité…

- Vision "fréquentiste" :
  - La probabilité est vue comme une fréquence "limite" de l'occurrence d'un événement aléatoire, lorsque le nombre d'essais n tend vers l'infini
  - Exemple : pile ou face
    - $X_i = 1$ si le résultat du tirage n°i est "Face"
    - $X_i = 0$ si le résultat du tirage n°i est "Pile"
    - Alors si n est le nombre de tirages :

$$\mathbb{P}(\text{"Face"}) = \lim_{n\to\infty} \frac{1}{n} \sum_{i=1}^{n} X_i$$

  - Cette interprétation de la probabilité est typiquement associée à des événements répétables :
    - Intérêt "historique" des fondateurs du calcul des probabilités pour les jeux de hasard (Fermat et Bernoulli, 1654)
    - Loi des grands nombres (Bernoulli, Poisson)
    - Quid pour des événements non répétables ?

Deux interprétations différentes de la probabilité…

- Vision "subjective" :
  - La probabilité est vue comme une traduction numérique d'un état de connaissance - cette traduction n'est pas arbitraire, mais respecte des critères de rationalité
  - La probabilité subjective est associée à la notion de pari - la probabilité d'un événement dépend du montant qu'un individu "rationnel" est prêt à parier sur cet événement

> La personne idéalement cohérente, que par commodité j'appellerai souvent « vous », est dite considérer l'événement A comme plus probable que l'événement B à la condition suivante : si vous pouviez recevoir une récompense particulière si et seulement si A est réalisé, ou si et seulement si B est réalisé, alors vous choisirez l'option qui associe la récompense à A.

[Savage, 1968]
Probabilité personnelle et induction,
Mathématiques et Sciences Humaines, vol. 23, pp. 5-15, 1968

- D'habitude, on fait remonter les origines de la vision "subjective" de la probabilité au Révérend Thomas Bayes…

… Mais une seule axiomatique

- Mathématiquement, la probabilité se définit par des propriétés fondamentales… qui ne dépendent pas de l'interprétation "subjective" ou "fréquentiste" :
  - Soit (Ω, T) un espace "probabilisable(é)" (muni d'une tribu $T^{(*)}$) :

$$\begin{cases} \mathbb{P}(A) \in [0;1], \forall A \in T \\ \mathbb{P}(\Omega) = 1 \\ \text{si } A_1, A_2, \dots, A_n \in T \text{ avec } A_j \cap A_k = \emptyset \text{ pour } j \neq k \text{ alors } \mathbb{P}\left(\bigcup_{i=1}^{n} A_i\right) = \sum_{i=1}^{n} \mathbb{P}(A_i) \end{cases}$$

$^{(*)}$ famille d'événements de Ω telle que :

$$\begin{cases} \Omega \text{ et } \emptyset \in T \\ A \in T \Rightarrow A^C \in T \\ \text{si } A_1, A_2, \dots, A_n \in T \text{ alors } \bigcup_{i=1}^{n} A_i \in T \end{cases}$$

Indépendance et probabilité conditionnelle

- Soient A et B deux événements de Ω :

$$\mathbb{P}(\mathrm{A}|\mathrm{B}) = \frac{\mathbb{P}(\mathrm{A} \cap \mathrm{B})}{\mathbb{P}(\mathrm{B})} \text{ avec } \mathbb{P}(\mathrm{B}) \neq 0 \quad \Rightarrow \quad \mathbb{P}(\mathrm{A} \cap \mathrm{B}) = \mathbb{P}(\mathrm{A}|\mathrm{B})\mathbb{P}(\mathrm{B})$$

- Indépendance :

$$\mathbb{P}(\mathrm{A} \cap \mathrm{B}) = \mathbb{P}(\mathrm{A})\mathbb{P}(\mathrm{B}) \quad \Leftrightarrow \quad \mathbb{P}(\mathrm{A}|\mathrm{B}) = \mathbb{P}(\mathrm{A})$$

Le fait de savoir que l'événement B s'est vérifié préalablement ne modifie pas la probabilité que l'événement A se vérifie !

N.B : Dépendance $\neq$ Causalité !!!

- De la définition de probabilité conditionnelle découle, de manière triviale, la formule de Bayes :

$$\mathbb{P}(\mathrm{A}|\mathrm{B}) = \frac{\mathbb{P}(\mathrm{A} \cap \mathrm{B})}{\mathbb{P}(\mathrm{B})} = \frac{\mathbb{P}(\mathrm{B} \cap \mathrm{A})}{\mathbb{P}(\mathrm{B})} \quad \text{puis} \quad \mathbb{P}(\mathrm{A}|\mathrm{B}) = \frac{\mathbb{P}(\mathrm{B}|\mathrm{A})\mathbb{P}(\mathrm{A})}{\mathbb{P}(\mathrm{B})}$$

car $\mathbb{P}(\mathrm{B} \cap \mathrm{A}) = \mathbb{P}(\mathrm{B}|\mathrm{A})\mathbb{P}(\mathrm{A})$

Approche "bayésienne" ?

- Jusqu'ici, les notions de probabilité "fréquentiste" ou "subjective" n'interviennent pas
- Les propriétés mathématiques de la probabilité, la définition de probabilité conditionnelle et le théorème de Bayes ne font pas l'objet de discussion entre fréquentistes et bayésiens
- Ce qui différencie la statistique "classique" et la statistique "bayésienne" est l'utilisation de la formule de Bayes

Retour sur la formule de Bayes (cas discret)

- Soit $\{H_i\}_{i\geq 1}$ une partition d'un ensemble de causes ou d'hypothèses possibles pour la réalisation d'un événement B :
  - L'union de toutes les H_i forme toutes les causes possibles de B :
    - Exemple :
      - B : "mon jardin est mouillé ce matin"
      - H_1 : "il a plu cette nuit"
      - H_2 : "mon arroseur s'est déclenché de façon intempestive"

Formule de Bayes

$$\mathbb{P}(H_i|B) = \frac{\mathbb{P}(B|H_i)\mathbb{P}(H_i)}{\mathbb{P}(B)}$$

Formule des probabilités "totales"

$$\mathbb{P}(B) = \sum_{i\geq 1} \mathbb{P}(B|H_i)\mathbb{P}(H_i)$$

$$\mathbb{P}(H_i|B) = \frac{\mathbb{P}(B|H_i)\mathbb{P}(H_i)}{\sum_{i\geq 1} \mathbb{P}(B|H_i)\mathbb{P}(H_i)}$$

Probabilité de la cause H_i, sachant que l'événement B a été observé

Interprétation "bayésienne" de la formule de Bayes

$$\mathbb{P}(H_i|B) = \frac{\mathbb{P}(B|H_i)\mathbb{P}(H_i)}{\sum_{i\geq 1}\mathbb{P}(B|H_i)\mathbb{P}(H_i)}$$

- Le théorème de Bayes permet de calculer la probabilité de la cause H_i en tenant compte de deux choses :
  - La connaissance initiale que j'avais sur H_i : $\mathbb{P}(H_i)$
  - La survenue de l'événement B
- A partir de ces éléments, le théorème de Bayes dit comment calculer $\mathbb{P}(H_i|B)$, la probabilité de H_i sachant que B s'est réalisé
- C'est un théorème de réactualisation de la connaissance

Exercice 3.1 – garantie site

- Exercice 3.1 :
  - Trois sites (S_1, S_2, S_3) fabriquent un même type d'appareil électroménager :
    - Ils assurent respectivement 50%, 35% et 15% de la production de ces matériels
    - Le REX permet de constater B, à savoir les retours de garantie à 2 ans suivants :
      - $\mathbb{P}(B|S_1) = 0.003$
      - $\mathbb{P}(B|S_2) = 0.008$
      - $\mathbb{P}(B|S_3) = 0.01$
  - Calculer la probabilité qu'un appareil proviennent d'un site S_i, sachant qu'il a été défectueux sur la période de garantie considérée

Exercice 3.2 – maladie tropicale

- Exercice 3.2 :
  - Un touriste revenant de vacances passe un test permettant de détecter une maladie tropicale rare, qui touche 1 personne sur 10000 :
    - Le test est toujours positif pour un malade
    - Le test est négatif pour les non-malades dans 95% des cas
    - Le touriste passe le test : il est positif
  - Calculer la probabilité que le touriste soit effectivement malade

Exercice 3.3 – dilemme du prisonnier

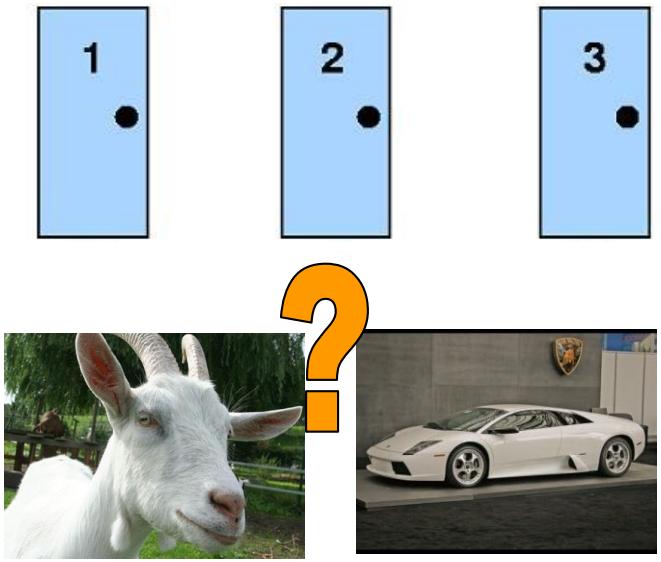

- Vous êtes invité à un jeu télévisé. Le présentateur vous propose d'ouvrir une porte parmi 3. Derrière 1 d'entre elles, se trouve une voiture ; derrière les autres, une chèvre. Si vous trouvez la voiture, vous repartez avec
- Vous choisissez une porte :
  - Le présentateur, pour vous aider, décide d'ouvrir 1 porte parmi les 2 qui restent
  - Evidemment, derrière la porte ouverte par le présentateur se trouve une chèvre

- Maintenant, le présentateur vous propose de revenir sur votre choix initial avant d'ouvrir la porte que vous lui indiqueriez
- Que feriez-vous ?
  - Je reste sur ma décision initiale, de toute façon, j'ai "1 chance sur 2" (?)
  - Je change de porte

Principe de l'approche bayésienne

Approche bayésienne

- Le théorème de Bayes permet d'inverser les probabilités conditionnelles et de retrouver la probabilité des "causes" sachant que leurs effets se sont vérifiés
- En statistique bayésienne, le théorème de Bayes est utilisé pour réactualiser la connaissance préalable sur les paramètres $\boldsymbol{\theta}$ d'un modèle après l'observation des données
- Modèle :
  - Représente formellement un phénomène aléatoire, comme le résultat de n lancers d'une pièce de monnaie (modèle binomial de paramètres (n,p))
  - Décrit l'incertitude (irréductible) liée à la nature du phénomène étudié
  - Même en ayant une connaissance parfaite du paramètre p (par exemple $p = 0.5$), le nombre m de "faces" après n lancers sera toujours incertain
  - Au modèle, une fois les données $\mathbf{x} = (x_1, ..., x_n)$ observées, on associe la fonction de vraisemblance $\mathcal{L}(\mathbf{x};\boldsymbol{\theta}) = \mathcal{L}(\mathbf{x}|\boldsymbol{\theta})$, qui est une fonction des paramètres $\boldsymbol{\theta}$

Approche bayésienne

- En statistique bayésienne, les paramètres $\boldsymbol{\theta}$ d'un modèle sont des variables aléatoires
- Il y a une mesure de probabilité "unique" pour décrire l'incertitude liée à la nature aléatoire d'un phénomène (ex. "pile" ou "face") et l'incertitude "épistémique" liée à la connaissance imparfaite des paramètres $\boldsymbol{\theta}$ qui régissent le phénomène
- Formule de Bayes (cas continu) :

$$\mathrm{p}(\boldsymbol{\theta}|\mathbf{x}) = \frac{\mathcal{L}(\mathbf{x}|\boldsymbol{\theta})\mathrm{p}(\boldsymbol{\theta})}{\int_{\Theta} \mathcal{L}(\mathbf{x}|\boldsymbol{\theta})\mathrm{p}(\boldsymbol{\theta})\mathrm{d}\boldsymbol{\theta}}$$

  - $\mathrm{p}(\boldsymbol{\theta})$: loi dite *a priori* de $\boldsymbol{\theta}$, souvent notée $\pi(\boldsymbol{\theta})$
    - Modélise la connaissance préliminaire (avant l'observation des données) sur la variable $\boldsymbol{\theta}$ par une distribution de probabilité
    - Peut elle-même dépendre de paramètres $\boldsymbol{\alpha}$, appelés hyperparamètres : $\pi(\boldsymbol{\theta}) = \mathrm{p}(\boldsymbol{\theta}|\boldsymbol{\alpha})$
    - Concrètement, elle vient :
      - De l'interrogation d'experts
      - De résultats obtenus avec des données similaires
      - Peut aussi traduire un manque complet de connaissance (loi *a priori* non informative ou peu informative)

Approche bayésienne

$$\mathrm{p}(\boldsymbol{\theta}|\mathbf{x}) = \frac{\mathcal{L}(\mathbf{x}|\boldsymbol{\theta})\mathrm{p}(\boldsymbol{\theta})}{\int_{\Theta} \mathcal{L}(\mathbf{x}|\boldsymbol{\theta})\mathrm{p}(\boldsymbol{\theta})\mathrm{d}\boldsymbol{\theta}}$$

- $\mathcal{L}(\mathbf{x}|\boldsymbol{\theta})$: vraisemblance des données
  - Modélise l'apport d'information des données – c'est une fonction des paramètres θ, puisque les données $\mathbf{x}$ sont connues
- $\mathrm{p}(\boldsymbol{\theta}|\mathbf{x})$: loi dite *a posteriori* de θ
  - Modélise la (nouvelle) connaissance sur θ conditionnellement à l'observation des données $\mathbf{x}$
- L'intégrale au dénominateur ne joue aucun rôle :
  - Comme on intègre sur la variable θ et que les $\mathbf{x}$ sont connues, c'est une simple constante pour normaliser $\mathrm{p}(\theta|\mathbf{x})$ et faire en sorte que :

$$\int_{\Theta} \mathrm{p}(\boldsymbol{\theta}|\mathbf{x})\,\mathrm{d}\boldsymbol{\theta} = \mathbf{1}$$

  - On notera donc :

$$\mathrm{p}(\boldsymbol{\theta}|\mathbf{x}) \propto \mathcal{L}(\mathbf{x}|\boldsymbol{\theta})\mathrm{p}(\boldsymbol{\theta})$$

sachant qu'on a en fait :

$$\mathrm{p}(\boldsymbol{\theta}|\mathbf{x};\boldsymbol{\alpha}) \propto \mathcal{L}(\mathbf{x}|\boldsymbol{\theta})\mathrm{p}(\boldsymbol{\theta}|\boldsymbol{\alpha})$$

Thomas Bayes

- Révérend Thomas Bayes (1701 ou 1702 – 1761), ministre du culte presbytérien - on sait peu de choses sur sa vie :
  - Membre de la Royal Society (1742)
  - On lui attribue deux documents publiés en vie :
    - *Divine benevolence, or an attempt to prove that the principal end of the divine providence and government is the happiness of his creatures* (1731)
    - *An introduction to the doctrine of fluxions, and a defence of the mathematicians against the objections of the author of the analyst*
- Article posthume : *Essay towards solving a problem in the doctrine of chances* (1763)

- Dans ce texte, Bayes évalue la probabilité que le paramètre p d'une loi binomiale appartienne à un intervalle donné, à partir des données observées (m succès sur n essais) et du fait que, *a priori*, rien n'est connu sur p
- Pour arriver à ce résultat, il utilise la formule… de Bayes
- Ce qui est "bayésien" dans l'article de Bayes, c'est le fait de définir une distribution sur le paramètre d'un modèle

Principe de l'inférence bayésienne

Données (de REX)
$\mathbf{x} = (x_1, x_2, \ldots, x_n)$

Modèle $\mathcal{L}(\mathbf{x}|\theta)$

Approche fréquentiste (max. de vraisembl.)

Connaissance *a priori*

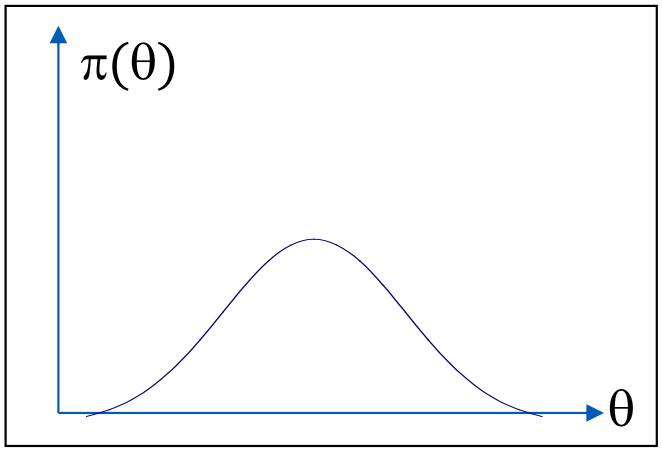

Mise à jour de la connaissance : formule de Bayes

$$p(\theta|\mathbf{x}) = \frac{\mathcal{L}(\mathbf{x}|\theta)\pi(\theta)}{\int_\Theta \mathcal{L}(\mathbf{x}|\theta)\pi(\theta)d\theta}$$

Connaissance *a posteriori*

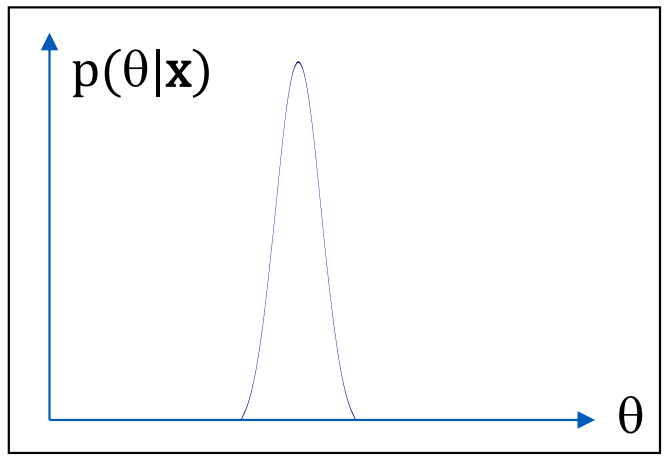

Comparaison des approches fréquentiste et bayésienne

Approche fréquentiste		Approche bayésienne
Paramètre du modèle		
Valeur déterministe (inconnue)	→	Variable aléatoire
Distributions *a priori* / *a posteriori*		
A priori sans objet	→	*A priori* explicitement déterminée
A posteriori sans objet	→	*A posteriori* déduite par le th. de Bayes
Rôle de l'expérience passée		
Via les données uniquement	→	Utilisable (expertise par exemple)
Modèle d'échantillonnage des données		
Supposé	→	Supposé
Intérêt de l'observation du REX		
Données pour les inférences (estimations)	→	Confirmation (ou non) de l'*a priori* sur la base de l'expérience passée

Approche bayésienne en fiabilité industrielle

Données de REX à disposition

- Dans tout le reste de l'exposé, on supposera que les données de REX à disposition sont issues de l'observation de composants non réparables :

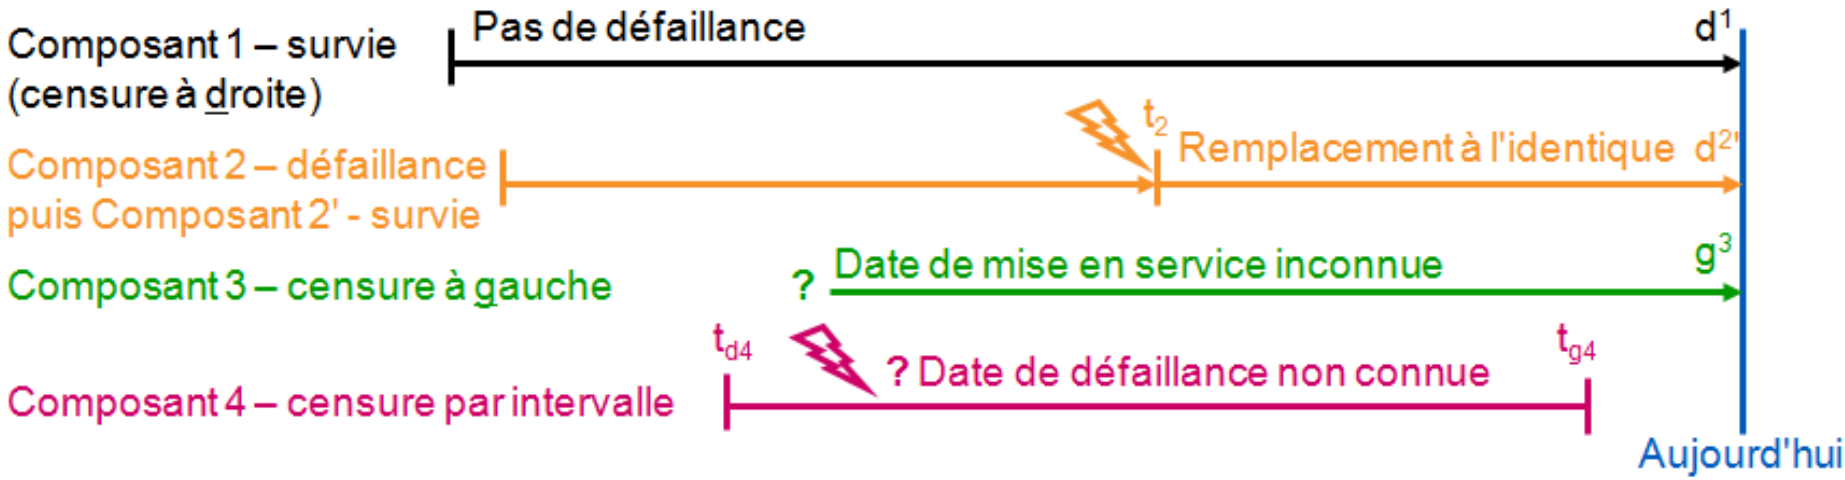

- On s'intéresse donc à la distribution de la variable aléatoire positive T représentant la durée de vie / temps à (unique) défaillance des composants

Expression générale de la fonction de vraisemblance

- Rappel sur l'approche fréquentiste (cf. exercice 2.4) : en supposant toutes les observations i.i.d

$$\mathcal{L}\left(t_i, g^j, d^k, t_d^\ell, t_g^\ell | \boldsymbol{\theta}\right) = \prod_i f_T(t_i|\boldsymbol{\theta}) \prod_j \mathbb{F}_T(g^j|\boldsymbol{\theta}) \prod_k \mathbb{R}_T(d^k|\boldsymbol{\theta}) \prod_\ell \left(\mathbb{R}_T(t_d^\ell|\boldsymbol{\theta}) - \mathbb{R}_T(t_g^\ell|\boldsymbol{\theta})\right)$$

avec :

- t_i : dates exactes de défaillance
- g^j : censures à gauche
- d^k : censures à droite (survies)
- t_d^ℓ et t_g^ℓ : censures par intervalle

Cas du modèle exponentiel

- Rappel (cf. partie 2) :

  - Fonction de fiabilité :

$$\mathbb{R}_T(t|\lambda) = 1 - \mathbb{F}_T(t|\lambda) = \exp(-\lambda t), \lambda > 0$$

  - Fonction de densité :

$$f_T(t|\lambda) = \frac{d\mathbb{F}_T(t|\lambda)}{dt} = \lambda\exp(-\lambda t), \lambda > 0$$

  - Fonction de répartition :

$$\mathbb{F}_T(t|\lambda) = \begin{cases} 1 - \mathbb{R}_T(t|\lambda) \\ \int_0^t f_T(u|\lambda)du \end{cases} = 1 - \exp(-\lambda t), \lambda > 0$$

  - Taux de défaillance :

$$\lambda_T(t|\lambda) = \frac{f_T(t|\lambda)}{\mathbb{R}_T(t|\lambda)} = \lambda, \lambda > 0$$

Cas du modèle exponentiel

- Rappel (cf. exercice 2.5) : si on observe
  - n composants i.i.d
  - Dont r sont tombés en panne aux dates connues t_i (et n'ont pas été remplacés)
  - Dont $n - r$ ne sont pas tombés en panne et sont en marche à la fin de leur observation aux dates d^k (censures à droite)
  - Alors l'estimateur (fréquentiste) par maximum de vraisemblance du paramètre λ du modèle exponentiel est :

$$\hat{\lambda}_{MV} = \frac{r}{\sum_{i=1}^{r} t_i + \sum_{k=r+1}^{n} d^k} = \frac{r}{T_{obs}(n)}$$

Qu'est-ce qu'une loi conjuguée ?

- Etant donné un modèle de paramètres $\boldsymbol{\theta}$, c'est-à-dire une fonction de vraisemblance $\mathcal{L}(\mathbf{x}|\boldsymbol{\theta})$, une loi conjuguée est une loi *a priori* pour $\boldsymbol{\theta}$ telle que la loi *a posteriori* de $\boldsymbol{\theta}$ appartienne à la même famille que l'*a priori* :

$$\mathrm{p}(\boldsymbol{\theta}|\mathbf{x}) \propto \mathcal{L}(\mathbf{x}|\boldsymbol{\theta})\pi(\boldsymbol{\theta})$$

$\pi(\boldsymbol{\theta})$ et $\mathrm{p}(\boldsymbol{\theta}|\mathbf{x})$ appartiennent à la même famille de loi

  - Les calculs sont très simples
  - Une expression analytique de la loi *a posteriori* est disponible

Exercice 3.4 – modèle exponentiel et loi conjuguée

- Exercice 3.4 :
  - Justifier l'emploi de la loi gamma comme loi *a priori* pour le paramètre λ du modèle exponentiel
  - Montrer que la loi gamma $\mathcal{G}(\alpha,\beta)$ est une loi conjuguée pour le paramètre λ du modèle exponentiel
  - Déterminer l'espérance *a posteriori* et les bornes de l'intervalle de crédibilité *a posteriori* à 95% de λ lorsque :
    - $r = 12$ défaillances et $n - r$ censures à droite
    - $T_{obs}(n) = 344440$ h
    - Un expert fournit les informations *a priori* suivantes sur λ :
      - Espérance *a priori* = 5×10^{-5} h^{-1}
      - Bornes de l'intervalle de crédibilité *a priori* à 95% : $[2.7\times10^{-5}\,;\,7.9\times10^{-5}]$
  - Interpréter les résultats obtenus

Quelques lois conjuguées

- Quelques lois conjuguées :

Vraisemblance $\mathcal{L}(x\|\theta)$	**Loi *a priori*** $\pi(\theta)$	**Loi *a posteriori*** $p(\theta\|x)$
Binomiale $\mathcal{B}(\theta,n)$	Beta $\mathcal{B}e(\alpha,\beta)$	Beta $\mathcal{B}e(\alpha+x,\beta+n-x)$
Poisson $\mathcal{P}(\theta)$	Gamma $\mathcal{G}(\alpha,\beta)$	Gamma $\mathcal{G}(\alpha+x,\beta+1)$
Gaussienne $\mathcal{N}(\theta,\sigma^2)$	Gaussienne $\mathcal{N}(\mu,\tau^2)$	Gaussienne $\mathcal{N}(\rho(\sigma^2\mu+\tau^2x),\rho\sigma^2\tau^2)$ avec $\rho^{-1} = \sigma^2+\tau^2$
Gaussienne $\mathcal{N}(\mu,1/\theta)$	Gamma $\mathcal{G}(\alpha,\beta)$	Gamma $\mathcal{G}(\alpha+0.5,\beta+(\mu-x)^2/2)$
Gamma $\mathcal{G}(\nu,\theta)$	Gamma $\mathcal{G}(\alpha,\beta)$	Gamma $\mathcal{G}(\nu+\alpha,\theta+\beta)$

Le cas "0 défaillance"

- On a pu constater que ce cas extrême pose problème dans le cadre de l'approche fréquentiste classique (cf. partie 2)
- En bayésien, même si $r = 0$, on peut mener les calculs jusqu'à leur terme (cf. exercice 3.4, l'*a posteriori* étant une loi gamma $\mathcal{G}(r+\alpha,\beta+T_{obs}(n))$)
- En revanche, se pose de façon accrue la question de la détermination de la loi *a priori*, qui n'est pas simple à calibrer du fait que la défaillance n'a jamais été observée et qui va jouer un rôle important…

Loi *a priori* non informative de Jeffreys

- Constat : la loi *a posteriori* est une "pondération" entre *a priori* et vraisemblance
  - Selon le poids relatif que l'on voudra donner entre connaissance *a priori* et données, on choisira une loi *a priori* plus ou moins informative vis-à-vis des observations ⇨ règle de bon sens
- Critique récurrente à l'analyse bayésienne : la subjectivité
  - Le choix d'une loi *a priori* serait un choix "arbitraire", alors que la statistique "fréquentiste" est "objective" car elle ne s'intéresse qu'aux données
- Recherche de lois *a priori* qui minimisent l'information ⇨ "Objective Bayes"
- Mon opinion :
  - Ces questions ont un intérêt théorique pour comparer les estimations fréquentiste et bayésienne
  - En pratique, si on a de l'information *a priori* (REX antérieur ou analogue, avis d'expert…), pourquoi s'en priver au nom d'une prétendue "objectivité" ?
- Une loi *a priori* "objective" : la loi de Jeffreys

Loi *a priori* non informative de Jeffreys

- Définition de la loi *a priori* non informative de Jeffreys :

$$\pi_0(\theta) \propto I(\theta)^{1/2} \propto \left[-\mathbb{E}_{X|\theta}\left(\frac{d^2 \ln\left(\mathcal{L}(x_1, \dots, x_n|\theta)\right)}{d\theta^2}\right)\right]^{1/2}$$

avec $I(\theta) = -\mathbb{E}_{X|\theta}\left(\frac{d^2 \ln\left(\mathcal{L}(x_1, \dots, x_n|\theta)\right)}{d\theta^2}\right)$ l'information de Fischer

  - Quantité d'information apportée par les observations $(x_1,\dots, x_n)$ sur le paramètre θ

- On peut montrer que ce choix minimise l'apport de l'information *a priori,* ou au contraire maximise l'information apportée par les données, c'est-à-dire maximise la distance entre lois *a priori* et *a posteriori* :

$$\pi_0 \cong \lim_{n\to\infty} \pi_n = \lim_{n\to\infty} \mathbb{E}\left(\int_\Theta \underbrace{p(\theta|(x_1, \dots, x_n)) \ln\left(p(\theta|(x_1, \dots, x_n))/\pi(\theta)\right) d\theta}_{\text{divergence de Kullback-Leibler entre lois } a \text{ posteriori et } a \text{ priori}}\right)$$

divergence de Kullback-Leibler entre lois *a posteriori* et *a priori* (mesure de dissimilarité – cf. transparent 60)

Exercice 3.5 – modèle exponentiel et loi *a priori* non informative de Jeffreys

- Exercice 3.5 :
  - Donner une expression de la loi *a priori* non informative de Jeffreys pour le paramètre λ du modèle exponentiel
  - En déduire les bornes de l'intervalle de crédibilité *a posteriori* à 95% de λ lorsque :
    - $n = 12$ défaillances (pas de cas de survie)
    - $T_{obs}(n) = 344440$ h
  - Interpréter les résultats obtenus

Quelle connaissance pour modéliser la loi *a priori* ?

- Données de REX "anciennes" : des modifications d'exploitation ou de maintenance font que ces données sont valables, mais moins que les récentes
  - Il est pertinent de considérer plusieurs périodes
- Données de REX analogues : même matériel mais exploité dans des conditions légèrement différentes, REX d'autres industries, REX étranger
  - Il est pertinent de l'utiliser pour augmenter la précision de l'estimation, car ce REX est complémentaire de celui observé sur le matériel étudié
- Avis d'experts (concepteur, exploitant) :
  - Nombreux biais à envisager
  - Une bonne façon d'avoir des bornes "minimale" et "maximale"

Quelle connaissance pour modéliser la loi *a priori* ?

- Dans tous les cas, il faut se poser la question de la pertinence de l'*a priori* relativement au REX à quantifier
  - Il doit être différent : ce sont deux connaissances qui n'ont rien à voir, qui sont complémentaires – l'idée générale est que la connaissance *a priori*, diffuse, vague (car concernant un parc de composants hétérogènes par exemple) est précisée par le REX étudié
  - Il doit être cohérent, c'est-à-dire pas trop précis, par rapport aux données de REX
- Il est important de rechercher la connaissance : utiliser "par principe" l'approche bayésienne avec des lois *a priori* non informatives ne présente pas d'intérêt en termes de résultat

Règles de bon sens dans le choix de l'*a priori*

- 4 cas de figure :
  - Neutralité de l'analyste – manque total de connaissance préliminaire :
    - *A priori* de Jeffreys
    - Conséquence : *a posteriori* déterminé uniquement par les données
  - Connaissance très imprécise de l'analyste : valeurs maxi. et mini. du paramètre, connaissances vague d'autres REX, *a priori* constructeur, programme de maintenance...
    - Lois *a priori* uniformes bornées
    - Conséquence : le support du paramètre est tronqué (probabilité *a priori* nulle ⇨ probabilité *a posteriori* nulle)

Règles de bon sens dans le choix de l'*a priori*

- Connaissance initiale plus précise (lois *a priori* informatives) :
  - Décrire ces connaissances par une loi conjuguée (si possible) : meilleur choix
  - Conséquences : pondération de la loi *a posteriori*, nécessité de valider la compatibilité entre *a priori* et REX (on injecte beaucoup d'information)
- Connaissance initiale très précise, via l'expertise ou des modèles physiques existants, des résultats expérimentaux (exemple : modélisation de la ténacité de l'acier de cuve : on sait quelle loi statistique est adaptée - dans ce cas, la loi imposée n'est pas forcément conjuguée) :
  - Distributions *a priori* quelconques
  - Conséquences : pas d'expression analytique de la loi *a posteriori*
    - Des techniques d'intégration numérique
    - Des techniques Monte-Carlo (échantillonnage pondéré, MCMC…)

Cas du modèle de Weibull

- Rappel (cf. partie 2) :

  - Fonction de fiabilité :

$$\mathbb{R}_T(t|\eta,\beta) = 1 - \mathbb{F}_T(t|\eta,\beta) = \exp\left(-\left(\frac{t}{\eta}\right)^{\beta}\right), \eta, \beta > 0$$

  - Fonction de densité :

$$f_T(t|\eta,\beta) = \frac{d\mathbb{F}_T(t|\eta,\beta)}{dt} = \frac{\beta}{\eta}\left(\frac{t}{\eta}\right)^{\beta-1} \exp\left(-\left(\frac{t}{\eta}\right)^{\beta}\right), \eta, \beta > 0$$

  - Fonction de répartition :

$$\mathbb{F}_T(t|\eta,\beta) = \begin{cases} 1 - \mathbb{R}_T(t|\eta,\beta) \\ \int_0^t f_T(u|\eta,\beta)du \end{cases} = 1 - \exp\left(-\left(\frac{t}{\eta}\right)^{\beta}\right), \eta, \beta > 0$$

  - Taux de défaillance :

$$\lambda_T(t|\eta,\beta) = \frac{f_T(t|\eta,\beta)}{\mathbb{R}_T(t|\eta,\beta)} = \frac{\beta}{\eta}\left(\frac{t}{\eta}\right)^{\beta-1}, \eta, \beta > 0$$

Cas du modèle de Weibull

- Pas de loi conjuguée, entre autres du fait de la complexité de l'expression de la fonction de vraisemblance
- Illustration de l'expression "analytique" de la loi *a posteriori* pour :
  - Un REX composé de r dates exactes de défaillance et $n - r$ censures à droite
  - Une loi *a priori* jointe sur les 2 paramètres (η,β) notée $\pi(\eta,\beta)$

$$p(\eta,\beta|t_1,\dots,t_r,d^{r+1},\dots,d^n) = \frac{\pi(\eta,\beta)\left(\frac{\beta}{\eta^\beta}\right)^r \prod_{i=1}^r (t_i)^{\beta-1} \exp\left(-\frac{1}{\eta^\beta}\left(\sum_{i=1}^r (t_i)^\beta + \sum_{k=r+1}^n (d^k)^\beta\right)\right)}{\iint_{\mathbb{R}+} \pi(\eta,\beta)\left(\frac{\beta}{\eta^\beta}\right)^r \prod_{i=1}^r (t_i)^{\beta-1} \exp\left(-\frac{1}{\eta^\beta}\left(\sum_{i=1}^r (t_i)^\beta + \sum_{k=r+1}^n (d^k)^\beta\right)\right) d\eta d\beta}$$

Que faire ?

- La résolution analytique de l'intégrale au dénominateur n'est pas faisable
- De plus, se poserait le problème du calcul des moments de cette loi *a posteriori* (encore des intégrales !)
- Que faire ?

- L'intégrale au dénominateur n'est qu'une constante de normalisation pour la loi *a posteriori* de $\boldsymbol{\theta} = (\eta,\beta)$
- Il existe des méthodes pour obtenir des réalisations $(\boldsymbol{\theta}_1,\ldots,\boldsymbol{\theta}_n)$ d'une variable aléatoire $\boldsymbol{\Theta}$ dont la loi de probabilité $p_{\boldsymbol{\Theta}}(\boldsymbol{\theta})$ est connue à une constante près

Méthodes Monte-Carlo pour l'inférence bayésienne

- 2 grandes familles de méthodes :
  - Simulation Monte-Carlo avec indépendance : acceptation-rejet, échantillonnage pondéré…
  - Simulation Monte-Carlo par chaînes de Markov (MCMC) : Metropolis-Hastings, Gibbs…
- Ces méthodes sont relativement anciennes (années 70) - les méthodes Monte-Carlo datent de l'époque du projet "Manhattan" (bombe atomique de la 2ème guerre mondiale) et la théorie des chaînes de Markov est encore plus ancienne (19ème siècle)
- La disponibilité, à partir des années 90, d'ordinateurs de plus en plus puissants et de moins en moins chers, a rendu ces méthodes de simulation intéressantes et cela a contribué à relancer l'intérêt pour la statistique bayésienne
- Aujourd'hui, l'argument de la "difficulté" d'obtenir la loi *a posteriori* dans les cas "non conjugués" n'est plus vraiment d'actualité

Exercice 3.6 – acceptation-rejet

- Exercice 3.6 :
  - Soit $p(.)$ la densité d'une loi d'intérêt (ou cible) délicate à simuler directement (par exemple seulement connue à une constante multiplicative près)
  - Supposons qu'il existe une "loi de proposition" de densité $\varphi(.)$, dite "loi instrumentale", qu'on sait facilement simuler et qui vérifie : $p(\theta) \leq M\varphi(\theta)$ sur tout le support de p, avec $M \geq 1$ une constante
  - Montrer que la procédure suivante, dite d'acceptation-rejet, fournit bien des réalisations de loi p :
    - Générer θ^* suivant $\varphi(.)$ et $u \rightsquigarrow \mathcal{U}(0,1)$ uniforme sur $[0\ ;\ 1]$
    - Accepter θ^* comme réalisation de $p(.)$ si $u \leq p(\theta^*)/[M\varphi(\theta^*)]$, sinon la rejeter
    - Itérer

Echantillonnage pondéré (ou préférentiel ou d'importance)

- Exemple : on cherche à estimer l'espérance $\mathbb{E}(\theta)$, avec $\theta \rightsquigarrow p(\theta)$ connue à une constante multiplicative près
- Au lieu de générer des valeurs selon $p(\theta)$, on tire dans une autre densité instrumentale $\varphi(\theta)$
- On sait que : $\mathbb{E}(\theta) \cong \frac{\sum_{i=1}^{n} \theta_i \omega_i}{\sum_{i=1}^{n} \omega_i}$
- C'est-à-dire : $\mathbb{E}(\theta) \cong \sum_{i=1}^{n} \theta_i \omega_i'$ avec $\omega_i' = \frac{\omega_i}{\sum_{i=1}^{n} \omega_i} = \frac{p(\theta_i)/\varphi(\theta_i)}{\sum_{i=1}^{n} p(\theta_i)/\varphi(\theta_i)}$ des poids normalisés dans lesquels la constante inconnue de p apparaît au numérateur et au dénominateur et donc disparaît
- Il est donc toujours possible de calculer les poids normalisés et donc d'estimer $\mathbb{E}(\theta)$ à partir d'un échantillon $(\theta_1,..., \theta_n)$ issu de la loi $\varphi(\theta)$ connue, qu'on va choisir simple à simuler (par exemple la loi *a priori* ou une loi Gaussienne)

Echantillonnage pondéré (ou préférentiel ou d'importance)

- Cette même méthode peut être utilisée pour évaluer toute intégrale de la forme :

$$\int u(\theta)p(\theta)d\theta \left(= \int \left[\frac{u(\theta)p(\theta)}{\varphi(\theta)}\right] \varphi(\theta)d\theta \right)$$

- Pour simuler un échantillon selon p, on peut utiliser une technique de rééchantillonnage :
  - Générer un échantillon selon la loi instrumentale $\varphi(\theta)$ de taille m : $(\theta_1,..., \theta_m)$
  - Evaluer les poids normalisés ω'_i, $1 \leq i \leq m$
  - Tirer (avec remise) depuis l'échantillon $(\theta_1,..., \theta_m)$ avec les probabilités $(\omega'_1,..., \omega'_m)$ un nouvel échantillon de taille n (modèle d'urne)
  - Cette méthode produit des "doublons", car certaines valeurs du premier échantillon sont beaucoup plus probables que d'autres - pour limiter ce problème, m doit être plus grand que n (par exemple $m = 10 \times n$)
- Avertissement :
  - Méthode asymptotique
  - La loi instrumentale $\varphi(\theta)$ doit être "proche" de $p(\theta)$ pour éviter de tirer trop de points avec des faibles probabilités
  - Le support de $\varphi(.)$ doit contenir celui de $p(.)$, sinon certaines valeurs ne seront jamais échantillonnées

MCMC

- MCMC : Monte-Carlo Markov Chain (simulation Monte-Carlo par Chaînes de Markov)
- Idée :
  - Construire une chaîne de Markov ergodique de distribution stationnaire la loi cible, donc ici la loi $p(\theta)$ (loi *a posteriori* connue seulement à une constante près)
  - En partant d'une chaîne arbitraire :
    - On ajuste les états de la chaîne au cours du processus
    - On la stationnarise pour atteindre $p(\theta)$

MCMC

- Ces méthodes génèrent donc, à partir d'une valeur initiale θ_0, une suite aléatoire de valeurs de θ : $(\theta_0, \theta_1, \theta_2, ..., \theta_{r-1}, \theta_r, \theta_{r+1}, ..., \theta_m)$:
  - "Asymptotiquement" distribuées selon la loi "cible" $p(\theta)$ dont l'expression peut être partiellement connue (par exemple à une constante près)
  - C'est-à-dire qu'à partir d'un certain r, les valeurs obtenues sont un échantillon issu de $p(\theta)$
- La suite est générée selon un mécanisme aléatoire de type markovien (chaîne de Markov) :
  - θ_1 est généré aléatoirement à partir d'une loi de probabilité qui dépend de θ_0
  - θ_2 est généré aléatoirement à partir d'une loi de probabilité qui dépend de θ_1
  - ...
- Propriété de Markov : $\mathbb{P}(\theta_i|\theta_0, \theta_1, \theta_2, ..., \theta_{i-1}) = \mathbb{P}(\theta_i|\theta_{i-1})$ - l'état de la chaîne dépend uniquement de la valeur précédente
- Sous certaines conditions pour la chaîne (ergodicité = {irréductibilité – tous les états communiquent + apériodicité – les états ne reviennent pas cycliquement selon une période + récurrence positive – temps moyen fini pour revenir à un même état}), le mécanisme aléatoire a une loi asymptotique, dite "invariante stationnaire"

MCMC

- Avertissement :
  - Ce sont des méthodes asymptotiques
  - Il faut s'assurer que la chaîne a convergé (c'est-à-dire atteint la distribution stationnaire) pour utiliser les dernières valeurs simulées comme échantillon issu de $p(\theta)$

- Méthodes de contrôle de la convergence - 2 grandes familles :
  - Méthodes basées sur une seule chaîne (tests sur les dernières valeurs de la suite pour voir si elles sont identiquement distribuées)
  - Méthodes basées sur plusieurs chaînes "en parallèle" : on lance plusieurs chaînes à partir de valeurs initiales différentes et on teste si les dernières valeurs de chaque chaîne sont distribuées selon la même loi - si c'est le cas, comme la loi stationnaire est unique, alors cela veut dire que la convergence a été atteinte

MCMC – Metropolis-Hastings

- Algorithme de type acceptation-rejet :
  - Choisir une valeur initiale pour la suite : θ_0
  - Générer aléatoirement une valeur "candidate" θ^* à partir d'une loi "instrumentale" $\varphi(\theta|\theta_0)$ dépendant de θ_0
  - Evaluer la probabilité d'acceptation du candidat θ^* : $\rho(\theta^*,\theta_0) = \min\left(\frac{p(\theta^*)\varphi(\theta_0|\theta^*)}{p(\theta_0)\varphi(\theta^*|\theta_0)};1\right)$
  - Générer un nombre aléatoire u entre 0 et 1 selon une loi uniforme $\mathcal{U}(0,1)$:
    - Si $u \leq \rho(\theta^*,\theta_0)$, accepter le candidat - nouvelle valeur de la chaîne : $\theta_1 = \theta^*$
    - Si $u > \rho(\theta^*,\theta_0)$, rejeter le candidat - nouvelle valeur de la chaîne : $\theta_1 = \theta_0$ (la chaîne ne bouge pas)
  - Répéter la méthode à partir de la nouvelle valeur θ_1
  - Itérer
- La loi stationnaire de cette chaîne de Markov est la loi $p(\theta)$:
  - Même si $p(\theta)$ est connue à une constante près, on peut toujours évaluer la probabilité d'acceptation ρ
  - L'acceptation du candidat se fait selon un tirage d'une loi de Bernoulli de paramètre ρ
  - La convergence théorique vers $p(.)$ est assurée pour n'importe quelle loi instrumentale $\varphi(.)$ - en pratique, attention ! (trop ou trop peu de refus ⇨ convergence lente / le choix de la loi instrumentale est donc fondamental)

Méthode ABC

- ABC : Approximate Bayesian Computation
- Algorithme de type acceptation-rejet
- Repose sur 3 étapes : itération n°k
  - Simuler une valeur θ_k de la variable Θ selon la loi *a priori* $\pi(\theta)$
  - Simuler un échantillon $\mathbf{x}^*$ de la variable X sachant $\Theta = \theta_k$ ($\mathbf{x}^*$ de même taille que l'échantillon de données à disposition $\mathbf{x}$)
    - Si $d(\mathbf{x}^* - \mathbf{x}) \leq \varepsilon$, alors accepter θ_k comme $\theta_k \rightsquigarrow p(\theta | d(\mathbf{x}^* - \mathbf{x}) \leq \varepsilon)$, loi approchée de la loi *a posteriori* $p(\theta|\mathbf{x})$
    - Sinon rejeter θ_k
  - Itérer
- Méthode qui nécessite de :
  - Définir une distance d (Kolmogorov-Smirnov par exemple)
  - Fixer ε

Extensions possibles

(In)Compatibilité entre données de REX et loi *a priori*

- Exemple illustratif de la problématique (modèle exponentiel – loi conjuguée) :
  - L'*a priori* peut être construit à partir de données issues d'une technologie similaire mais ancienne (qui a donc fonctionné plus longtemps) alors que les données de REX (vraisemblance) concernent une technologie plus récente :
    - REX ancien : 10 défaillances en 100000 h ($\hat{\lambda}_{\mathrm{MV,ancien}} = 10^{-4}$ / h)
    - REX récent : 2 défaillances en 10000 h ($\hat{\lambda}_{\mathrm{MV,récent}} = 2\times10^{-4}$ / h)
    - Espérance *a posteriori* de $\lambda = 1.1\times10^{-4}$ / h
  - Le poids des données anciennes (*a priori*) est très important dans l'*a posteriori* - est-ce vraiment ce que l'on souhaite quand on réactualise une donnée de fiabilité ?
  - Il faut tout de même que le REX récent (vraisemblance) "compte"
  - Le mélange de 2 sources de connaissance ne peut donc pas être "objectif" : l'analyste doit faire des choix, des études de sensibilité

Loi *a priori* : $\mathcal{G}(10,100000)$

Loi *a posteriori* : $\mathcal{G}(12,110000)$

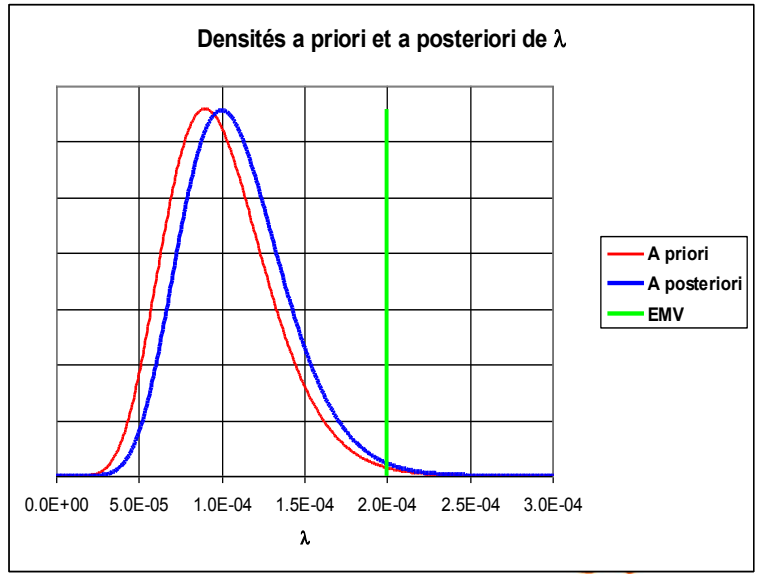

(In)Compatibilité entre données de REX et loi *a priori*

- Autre cas où les "poids" de l'*a priori* et du REX sont parfaitement équilibrés :
  - REX ancien (*a priori*) : 2 défaillances en 10000 h (2×10^{-4} / h)
  - REX récent (vraisemblance) : 10 défaillances en 10000 h (10^{-3} / h)
  - La valeur moyenne *a posteriori* (6×10^{-4} / h) est égale à la moyenne entre les 2 estimations et tient autant compte du REX ancien que du REX récent
  - Attention : les 2 sources de connaissance n'en restent pas moins peu compatibles

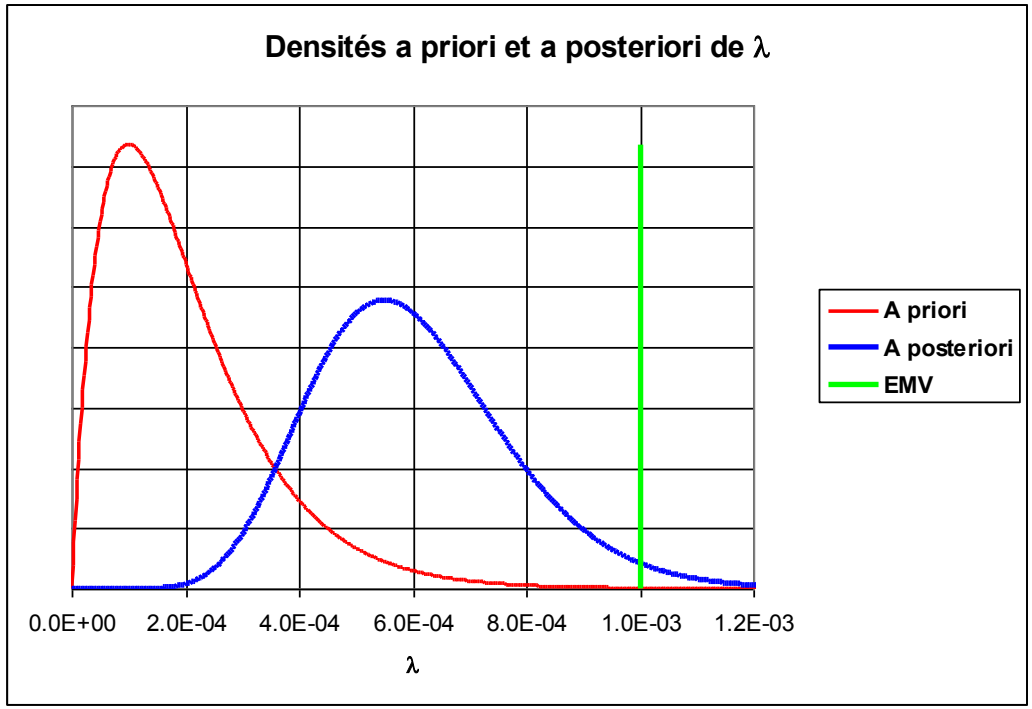

(In)Compatibilité entre données de REX et loi *a priori*

- Lorsqu'on dispose d'une connaissance *a priori* (par exemple fondée sur du REX ancien) et des données de REX (par exemple récentes), il est important de vérifier, avant le calcul bayésien, que les deux connaissances ne sont pas contradictoires :
  - En termes de précision
  - En termes d'estimation

- Si c'est le cas, on suggère de relâcher la précision de la connaissance *a priori* (augmenter l'incertitude = diminuer le poids relatif de l'*a priori*) jusqu'à ce que son mélange avec les données de REX ait un sens

(In)Compatibilité entre données de REX et loi *a priori*

- Exemple illustratif :

REX ancien (*a priori*)			REX récent (vraisemblance)		
$T_{obs,ancien}$	n_{ancien}	$\hat{\lambda}_{MV,ancien}$	$T_{obs,récent}$	$n_{récent}$	$\hat{\lambda}_{MV,récent}$
162319	17	1×10^{-4}	66810	14	2.1×10^{-4}

- Mélange simple des 2 sources de connaissance :
  - Espérance bayésienne *a posteriori* du taux de défaillance $= (14 + 17) / (162319 + 66810) = 1.35\times10^{-4}$ h^{-1}
  - Estimation par MV sur les données du REX récent = 2.1×10^{-4} h^{-1}

- On peut utiliser une méthode de pondération des 2 REX pour reconstruire une nouvelle loi *a priori* "compatible" :
  - Ramener, à taux de défaillance égal, le REX ancien (*a priori*) à 66810 h et donc le nombre de défaillances à $17 \times (66810 / 162319) \cong 7$ ⇨ loi *a priori* $\equiv \mathcal{G}(7,66810)$
  - Calcul des quantiles à 10% et 90% (intervalle à 80%) de cette loi *a priori* : $[4.9\times10^{-5} ; 1.8\times10^{-4}]$ ⇨ l'estimation par MV obtenue du REX récent n'est pas dans l'intervalle puisqu'elle vaut 2.1×10^{-4}
  - On considère que $[4.9\times10^{-5} ; 1.8\times10^{-4}]$ est un intervalle à 60% (au lieu de 80%) pour la loi *a priori* et on calcule les paramètres de la loi gamma (*a priori*) associée

(In)Compatibilité entre données de REX et loi *a priori*

- On obtient finalement une nouvelle loi *a priori* $\mathcal{G}(4.34,40300)$ compatible avec les données de REX récentes collectées :
  - Méthode de pondération tenant compte à la fois de la durée du REX récent et de l'estimation *a priori*
- Loi *a posteriori* : $\mathcal{G}(4.34+14,40300+66810)$ d'espérance 1.71×10^{-4} / h

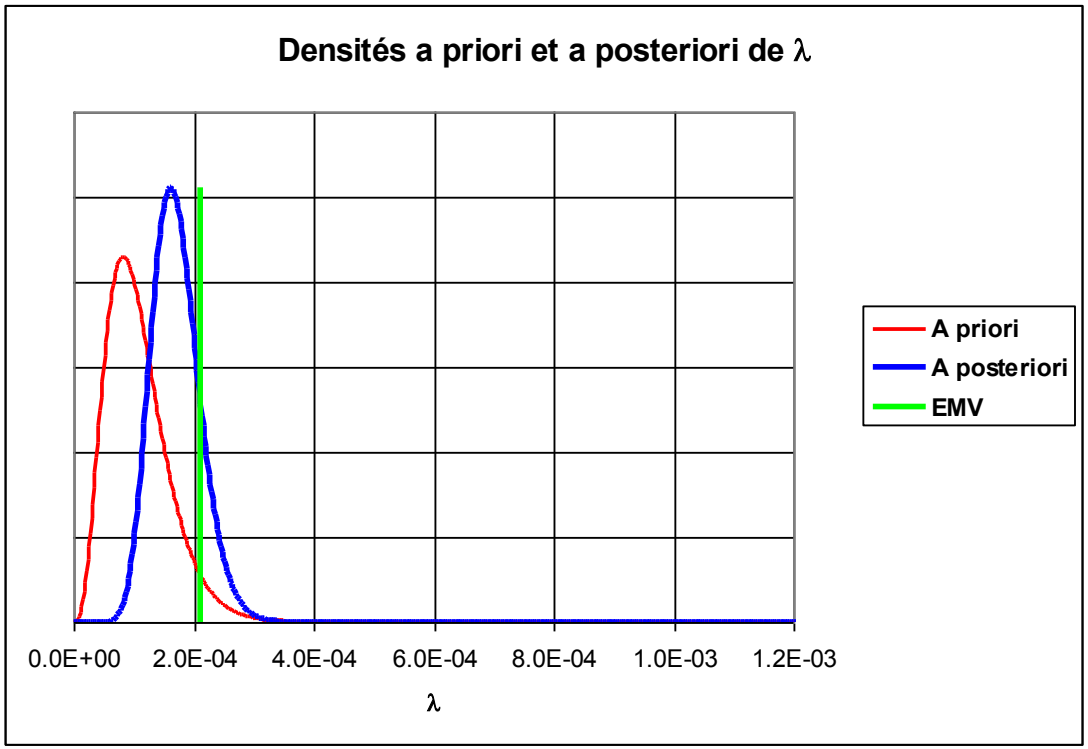

Critère DAC

- Plus formellement, [Bousquet, 2006] introduit un critère de "détection de conflit" entre loi *a priori* π et données $\mathbf{x}$, le DAC (pour Data-Agreement Criterion), défini par :

$$\mathrm{DAC}(\pi|\mathbf{x}) = \frac{\mathrm{KL}(p_0(.|\mathbf{x})\|\pi)}{\mathrm{KL}(p_0(.|\mathbf{x})\|\pi_0)}$$

  avec :
  - KL la divergence de Kullback-Leibler
  - π la loi *a priori*
  - π_0 la loi *a priori* non informative de Jeffreys
  - $p_0(.|\mathbf{x})$ la loi *a posteriori* obtenue avec l'*a priori* π_0 et les données $\mathbf{x}$
- On considérera que la loi *a priori* π est compatible avec les données $\mathbf{x}$ si $\mathrm{DAC}(\pi|\mathbf{x}) \leq 1$

Critère DAC

- On rappelle que pour 2 fonctions de densité f et g :
  - $KL(f||g) = \int_{\Theta} f(\theta)\ln\left(\frac{f(\theta)}{g(\theta)}\right)d\theta$
  - $KL(f||g) \geq 0$
  - $KL(f||g) = 0$ ssi $f = g$
  - KL mesure la différence entre f et g (quantité d'information perdue [regret] en choisissant g alors que la vraie distribution est f)
  - KL n'est pas une distance (pas de symétrie et non respect de l'inégalité triangulaire)
  - KL est invariante par re-paramétrisation

- Motivation :
  - π_0, en tant que loi *a priori* non informative, est "forcément" en accord avec les données $\mathbf{x}$ et la loi *a posteriori* $p_0(.|\mathbf{x})$ est "proche" de la vraisemblance (cf. exercice 3.5, sachant que par définition π_0 maximise $KL(p_0(.|\mathbf{x})||\pi_0)$)
  - Que π soit plus en accord avec les données $\mathbf{x}$ que ne l'est π_0, donc que $KL(p_0(.|\mathbf{x})||\pi) \leq KL(p_0(.|\mathbf{x})||\pi_0)$, est gage de bonne compatibilité entre la loi *a priori* π et les données $\mathbf{x}$

Utilisation de la loi *a posteriori*

- L'approche bayésienne permet de réactualiser la connaissance préalable sur le paramètre θ d'un modèle en calculant la loi *a posteriori* $p(\theta|\mathbf{x})$
- Mais que faire en pratique de cette loi *a posteriori* ?
- On définit l'estimateur bayésien par :

$$\hat{\theta}_{\text{Bayes}} = \arg\min_{d(\mathbf{x})\in\mathcal{D}} \int c(d(\mathbf{x}),\theta)p(\theta|\mathbf{x})d\theta$$

où $c(d(\mathbf{x}),\theta)$ est le coût (la perte) de prendre, en lieu et place de la décision optimale, la décision $d(\mathbf{x}) \in \mathcal{D}$ (l'ensemble des règles de décision) au vu des données $\mathbf{x}$, lorsque la variable aléatoire Θ vaut θ

  - L'estimateur bayésien peut donc être vu comme la décision "optimale", au sens de la fonction de coût c, moyennée sur toutes les valeurs possibles de Θ (il minimise le "risque bayésien")
- Quelle fonction de coût retenir ?
  - Dépend des enjeux décisionnels ayant motivé l'étude

Utilisation de la loi *a posteriori*

- Par exemple :
  - Sans fonction de coût précisément définie, le mode *a posteriori* de la variable aléatoire Θ est le choix le plus naturel pour définir l'estimateur bayésien (pendant bayésien de l'estimateur par maximum de vraisemblance en fréquentiste)
  - L'espérance *a posteriori* de Θ est l'estimateur bayésien si on considère la fonction de coût quadratique $c(d(\mathbf{x}),\theta) = (d(\mathbf{x}) - \theta)^2$ (moindres carrés en régression fréquentiste)
  - Le quantile *a posteriori* d'ordre $k_2 / (k_1 + k_2)$ est l'estimateur bayésien si on considère la fonction de coût absolue de la forme :

$$c(d(\mathbf{x}),\theta) = \begin{cases} k_2\big(\theta - d(\mathbf{x})\big) \text{ si } \theta > d(\mathbf{x}) \\ k_1(d(\mathbf{x}) - \theta) \text{ sinon} \end{cases}$$

(k_1 et k_2 représentant les coûts de sous-estimation et de sur-estimation)

- La loi *a posteriori* peut être utilisée pour faire du choix de modèle au travers des facteurs de Bayes (ratio des probabilités *a posteriori* des hypothèses nulle (H.0) et alternative (H.1) sur le rapport *a priori* de ces mêmes hypothèses – pendant bayésien du rapport de vraisemblance en fréquentiste)

Réseaux bayésiens

- Reposent sur le théorème de Bayes, mais se basent sur une philosophie différente de l'approche bayésienne telle qu'on vient de l'introduire
- Principe général [wikipedia.org] :
  - Modèles graphiques probabilistes représentant des variables aléatoires sous la forme d'un graphe orienté acyclique - sont à la fois :
    - Des modèles de représentation des connaissances
    - Des "machines à calculer" les probabilités conditionnelles (d'où "bayésien(s)")
- Construction d'un réseau :
  - Définir la structure du réseau / le graphe, donc les relations causales entre les variables
  - Définir les tables de probabilité de chaque variable, conditionnellement à ses causes (nœuds parents – enfants)
- Utilisation d'un réseau (aussi appelée "inférence") :
  - "Forward" (*a priori* – pronostic / conséquence) : étant donné les valeurs (ou modalités) des nœuds parents, calcul de la table conditionnelle du nœud enfant
  - "Backward" (*a posteriori* – diagnostic / cause) : étant donné la valeur (ou modalité) du nœud enfant, calcul des tables conditionnelles des nœuds parents
- Approche en vogue dans les années 2000 et aux domaines d'applications très variés

Réseaux bayésiens

- Exemple illustratif [bayesia.com] :
  - Cas d'un spécialiste des maladies des poumons désirant modéliser sa connaissance (très simplifiée) sur le diagnostic du cancer ou de la tuberculose
  - En fonction des symptômes (observés) d'un malade, calcul des probabilités des différentes pathologies compatibles avec ces symptômes

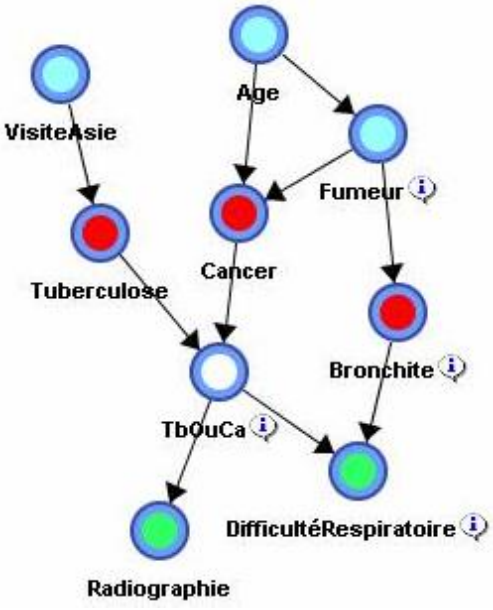

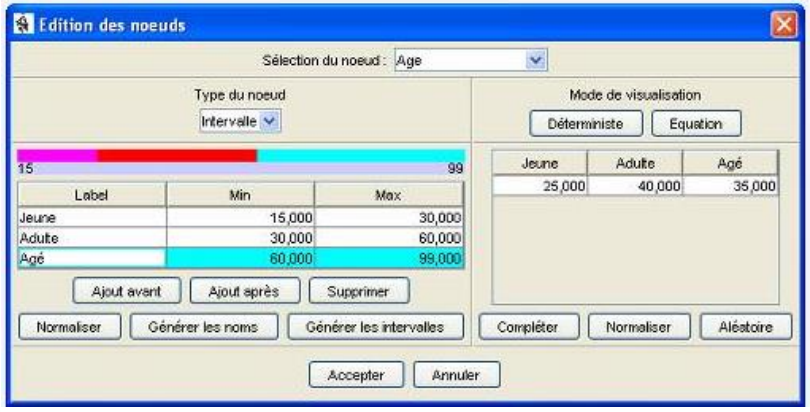

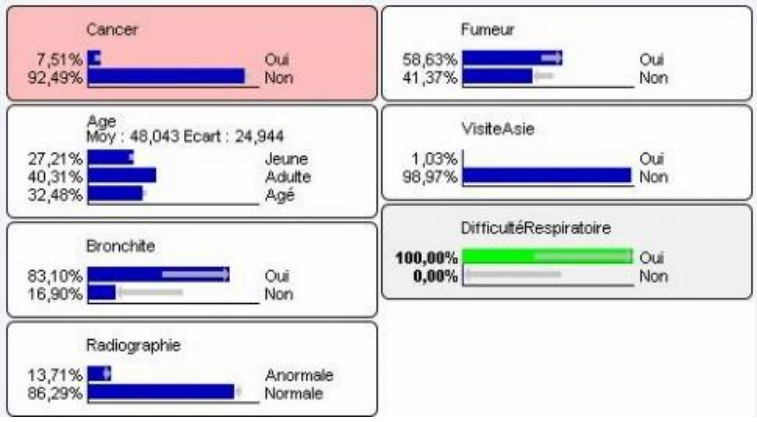

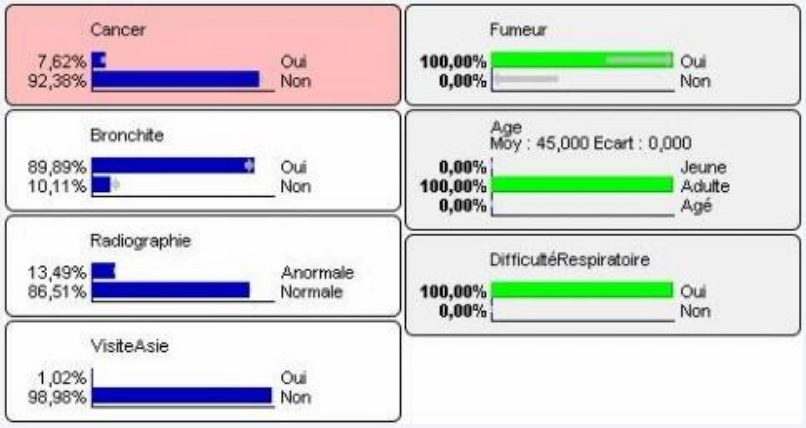

Réseaux bayésiens

- Intérêts en sûreté de fonctionnement :
  - Modélisation de systèmes (dynamiques) et simulation de leur comportement :
    - *Aide à l'optimisation de maintenance à partir de réseaux bayésiens et fiabilité dans un contexte doublement censuré*, F. Corset, mémoire de thèse de doctorat de l'Université Joseph-Fourier - Grenoble I, 2003
    - *Modélisation de la fiabilité et de la maintenance par modèles graphiques probabilistes - Application à la prévention des ruptures de rail*, R. Donat, mémoire de thèse de doctorat de l'Institut National des Sciences Appliquées de Rouen, 2009
  - Prise en compte simultanément de connaissances *a priori* d'experts (construction du graphe) et de l'expérience contenue dans les données de REX (apprentissage des tables conditionnelles) :
    - *AVISE, une démarche d'anticipation du vieillissement par interrogation et stimulation d'experts, application à un matériel passif d'une centrale nucléaire : le pressuriseur*, L. Bouzaïene-Marle, mémoire de thèse de doctorat de l'Ecole Centrale Paris, 2005

Cas d'étude EDF pour illustration

Durée de vie du condenseur – contexte

- Contexte : évaluation de la "durée de vie" d'un condenseur
- REX disponible : dates de remplacement suite à atteinte du critère de fin de vie des demi-condenseurs en laiton (perte d'épaisseur des tubes de 50% en moyenne)
  - Nombreux remplacements avant 15 ans
  - Pas de demi-condenseur en laiton de plus de 20 ans en exploitation sur les centrales considérées
- Expertise EDF sur la durée de vie de ces demi-condenseurs :
  - Entre 20 et 30 ans (quantiles 5%-95%)
  - Médiane : 25 ans
- Autre expertise disponible : avis d'un constructeur (quantiles 5%-95%)
  - Entre 10 et 50 ans (quantiles 5%-95%)
  - Médiane : 25 ans

Durée de vie du condenseur – problématique

- A disposition :
  - 18 données, dont 8 censures à droite
  - Deux expertises très optimistes par rapport aux données de REX

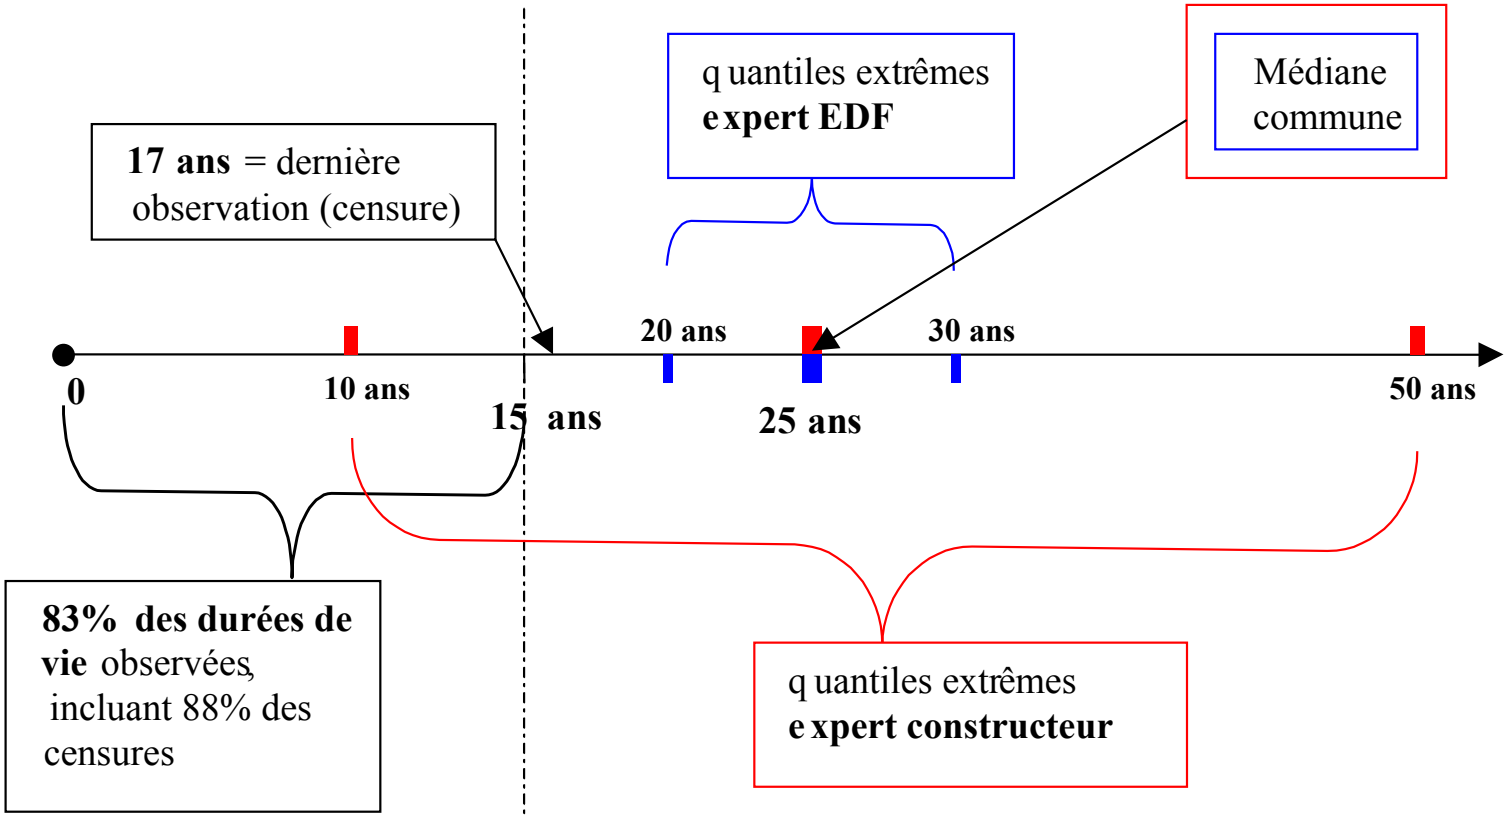

Durée de vie du condenseur – solution possible

- Est-ce pertinent d'agréger ces différentes sources d'information ?
- Si oui, comment ?
- Quels résultats obtient-on par rapport à une simple analyse fréquentiste à partir des données de REX ?
- L'approche bayésienne semble adaptée à ce contexte particulier, mais nécessite toutefois des précautions d'usage

Durée de vie du réducteur

- Contexte : évaluation de la "durée de vie" du réducteur d'un certain type de pompes
- REX disponible : 3 avaries sur 108 réducteurs ayant fonctionné plus de 3000 années au total
- Résultat d'un traitement fréquentiste de ces données :
  - Peu réaliste : espérance du temps à défaillance estimée à environ 500 années de fonctionnement
  - Peu précis : intervalle de confiance à 90% du MTTF entre 200 et 1260 années
- Mise en œuvre de l'approche bayésienne :
  - Recueil d'avis de constructeurs, d'exploitants, de mainteneurs et d'experts R&D des réducteurs
  - MTTF *a posteriori* estimé à 61 années avec un intervalle de crédibilité à 90% entre 50 et 82 années de fonctionnement
  - Estimation bayésienne vraisemblablement plus réaliste que l'estimation fréquentiste, mais encore peu précise et fortement dépendante des informations *a priori* fournies par les experts
  - Besoin de réaliser des études de sensibilité à la loi *a priori* pour rendre le résultat robuste

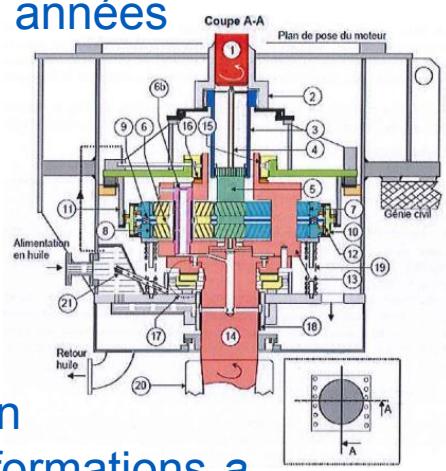

Outils logiciels

Outils logiciels

- Logiciels permettant de mettre en œuvre les algorithmes de simulation à partir de la description du modèle bayésien (loi *a priori* + vraisemblance) et des données :
  - WinBUGS [BUGS : Bayesian inference Using Gibbs Sampler] (https://www.mrc-bsu.cam.ac.uk/software/bugs/) et son pendant open source OpenBUGS, compatibles avec JAGS [Just Another Gibbs Sampler] (mcmc-jags.sourceforge.io/)
  - Multiples packages pour R, dont "BRUGS" (interface avec OpenBUGS : http://cran.r-project.org/web/packages/BRugs/index.html)
  - Plusieurs librairies également en Python, dont "PyMC3" (docs.pymc.io)
  - Stan [mc-stan.org] et ses "dérivées" RStan and PyStan pour R et Python

- Réseaux bayésiens :
  - BayesiaLab de Bayesia (bayesia.com)
  - Netica de NORSYS (norsys.com/netica.html)
  - aGrUM [A GRaphical Universal Model] (agrum.gitlab.io)

- Depuis plusieurs années, SAS (sas.com) propose :
  - Une PROC MCMC
  - Une instruction BAYES dans la plupart des PROC standard

Outils logiciels – exemple d'estimation des paramètres d'une loi de Weibull avec WinBUGS

REX (modèle de Weibull)

Durée observée (h)	Type de donnée
4380	Défaillance
1791	Défaillance
1611	Défaillance
1291	Défaillance
6132	Censure à droite
5694	Censure à droite
5296	Censure à droite
4818	Censure à droite
4818	Censure à droite
4380	Censure à droite

A priori sur les 2 paramètres de la loi de Weibull (2 lois *a priori* indépendantes)

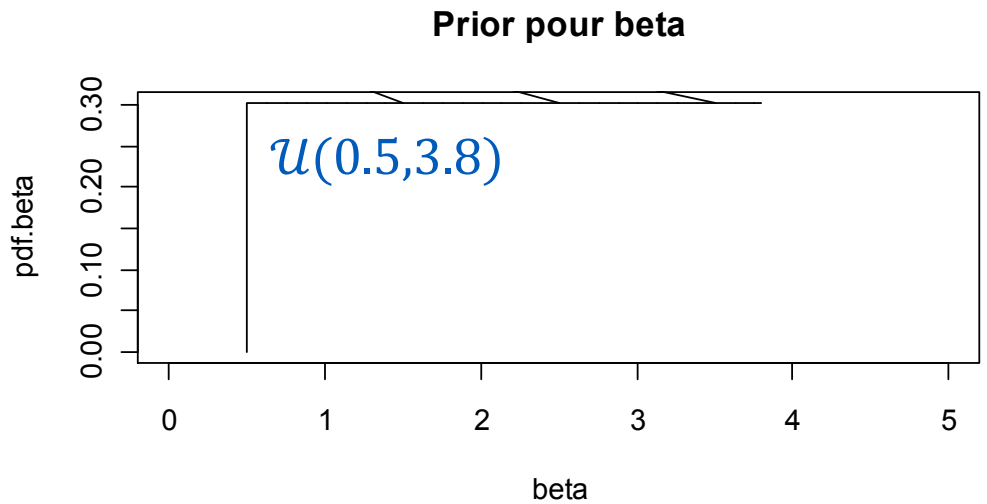

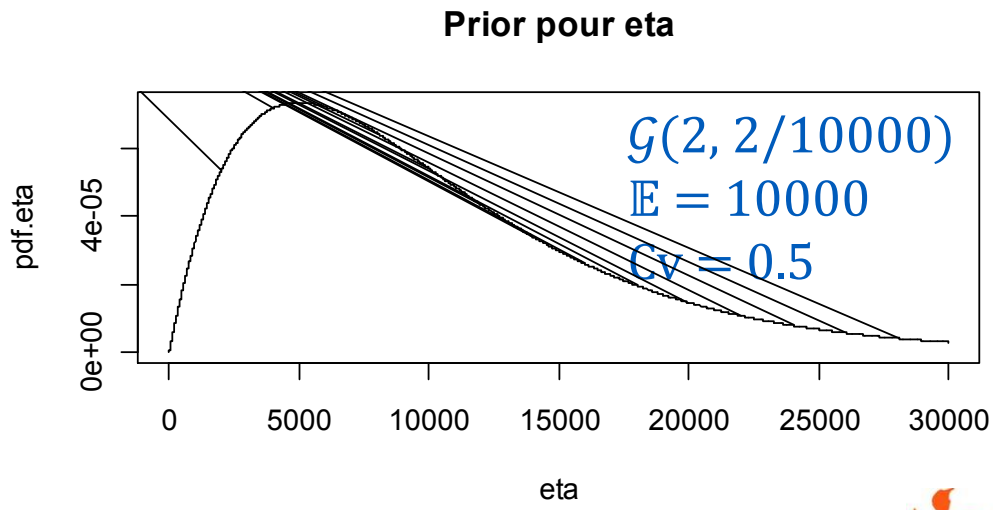

Outils logiciels – exemple d'estimation des paramètres d'une loi de Weibull avec WinBUGS

WinBUGS14 - [PriorsIndepB215_MANUAL]

File Tools Edit Attributes Info Model Inference Options Doodle Map Text Window Help

```
model
  {
    for(i in 1 : M) {
      t[i] ~ dweib(beta, mu)I(t.cen[i],)
      }
    mu<-pow(eta,-beta)

    # PRIORS
    beta<-beta0*(B2-B1)+B1
    beta0 ~ dbeta(p,q)
    eta ~ dgamma(a,b)
    a<-pow(1/CV,2)
    b<-1/(CV*CV*E)

  }

#DATA
list(
    t=c(4380,1791,1611,1291,NA,NA,NA,NA,NA,NA),
  t.cen=c(0,0,0,0,6132,5694,5296,4818,4818,4380),
  M=10,
  p=1,
  q=1,
  B2=3.8,
  B1=0.5,
  E=10000
  CV=0.5
  )

#INITS
list(eta=10000,beta0=0.2)
list(eta=12000,beta0=0.5)
```

Modèle de Weibull avec données censurées

Attention à la paramétrisation différente de la loi de Weibull selon le logiciel - ici $\mu=(1/\eta)^{\beta}$ à la place de η

Spécification des lois *a priori* (N.B : loi uniforme comme cas particulier de la loi beta)

Données de REX :

- **t = défaillances**
- **t.cen = données censurées**

Outils logiciels – exemple d'estimation des paramètres d'une loi de Weibull avec WinBUGS

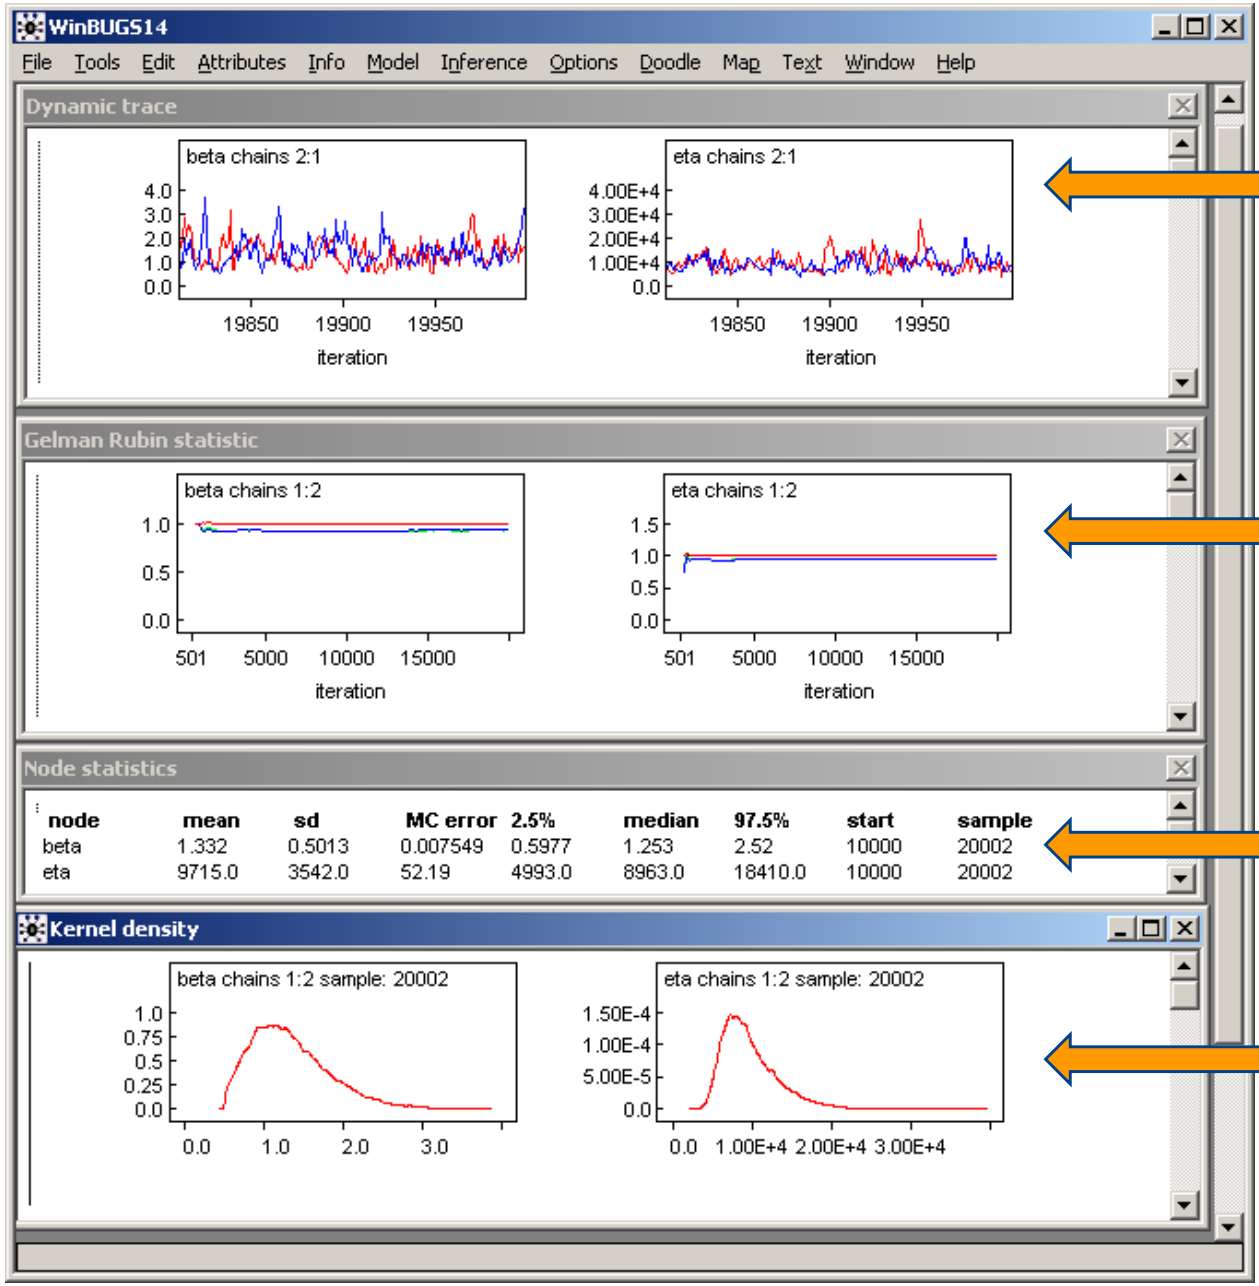

Résultats pour 20000 tirages MCMC

Historique des valeurs échantillonnées (2 chaînes)

Test de convergence - si valeur de la stat. de test proche de 1, OK

Moments et quantiles empiriques de la loi *a posteriori* sur la base des dernières 10000 valeurs de chaque chaîne

Densités "empiriques" *a posteriori*

N.B : les estimations par max. de vrais. sont 1.2 et 8750

Références bibliographiques

Références bibliographiques

- Statistique bayésienne :
  - [Droesbeke et al., 2002] - *Méthodes bayésiennes en statistique*, J-J. Droesbeke, J. Finne & G. Saporta, éditions Société Française de Statistique – Technip, 2002
  - [Gelman et al., 2006] - *Bayesian data analysis - 2nd edition*, A. Gelman et al., éditions Chapman & Hall, 2006
  - [Marin et al., 2006] - *Bayesian core*, J-M. Marin & C.P. Robert, éditions Springer, 2006
  - [Parent et al., 2007] - *Le raisonnement bayésien*, E. Parent & J. Bernier, éditions Springer, 2007
  - [Robert, 2006] - *Le choix bayésien*, C.P. Robert, éditions Economica, 2006

- Méthodes de Monte-Carlo :
  - [Robert et al., 2004] – *Monte-Carlo statistical methods - 2nd edition*, C.P. Robert & G. Casella, éditions Springer, 2004

Références bibliographiques

- Fiabilité bayésienne :

  - [Bacha et al., 1998] - *Estimation de modèles de durées de vie fortement censurées*, M. Bacha, G. Celeux, E. Idée, A. Lannoy & D. Vasseur, éditions Eyrolles, collection "EDF DER" n°99, 1998
  - [Bousquet, 2006] - *Analyse bayésienne de la durée de vie de composants industriels*, N. Bousquet, mémoire de thèse de doctorat de l'Université Paris XI Orsay, 2006
  - [Hamada et al., 2008] - *Bayesian reliability*, M.S. Hamada, A. Wilson, C.S. Reese & H. Martz, éditions Springer, collection "Series in Statistics", 2008
  - [Lannoy, 1996] - *Analyse quantitative et utilité du retour d'expérience pour la maintenance des matériels de sécurité*, A. Lannoy, éditions Eyrolles, collection "EDF DER" n°93, 1996
  - [Procaccia et al., 2003] - *Démarche bayésienne et applications à la SdF*, H. Procaccia, M-C. Suhner et al., éditions Lavoisier, collection "Hermès", 2003

Quelques éléments de conclusion

Que retenez-vous ?

Derniers messages

- Une approche originale, très utile dans le contexte spécifique présenté
- Un domaine en plein essor, en particulier grâce à l'augmentation de la puissance de calcul
- Des applications dans tous les domaines et sous différentes formes, pas uniquement en fiabilité industrielle

Science & Vie n°1142 de novembre 2012